


Day 4

# スパース解をもつ凸緩和問題

- BP: Basis pursuit

$$\underset{\mathbf{x}}{\text{Minimize}} \|\mathbf{x}\|_1 \quad \text{subject to} \quad \mathbf{Ax} = \mathbf{b}$$



- $\text{BP}_\delta$ : Constrained BP denoising

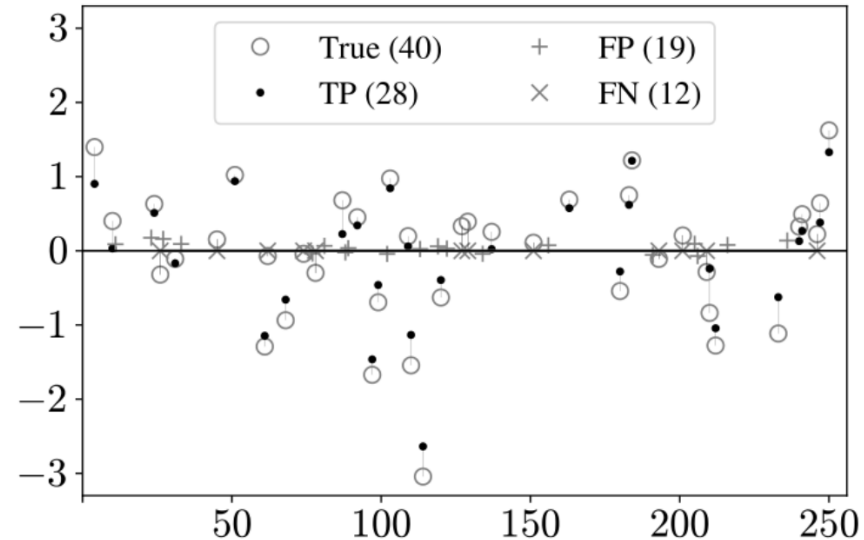
$$\underset{\mathbf{x}}{\text{Minimize}} \|\mathbf{x}\|_1 \quad \text{subject to} \quad \|\mathbf{b} - \mathbf{Ax}\|_2 \leq \delta$$

- LASSO: least absolute shrinkage and selection operator


$$\underset{\mathbf{x}}{\text{Minimize}} \|\mathbf{b} - \mathbf{Ax}\|_2 \quad \text{subject to} \quad \|\mathbf{x}\|_1 \leq \tau$$

- LASSO regression / unconstrained BP denoising (BPDN) /  $\ell_1$ -regularized least squares ( $\ell_1$ -LS)

$$\underset{\mathbf{x}}{\text{Minimize}} \frac{1}{2} \|\mathbf{b} - \mathbf{Ax}\|_2^2 + \lambda \|\mathbf{x}\|_1$$



(a) FISTA による復元  $\hat{\mathbf{x}} = \mathbf{x}^{(30)}$



(b) デバイアス後

図 3.22 正規乱数の非ゼロ成分をもつスパース解を FISTA で復元した例. True は正解  $\mathbf{x}^\circ \in \mathbb{R}^{256}$  の非ゼロ成分である. 正答 TP, 誤検出 FP, 検出漏れ FN の意味は図 3.8 を参照のこと.




図 3.15 解パスの例. 非ゼロ成分の数と値は  $\lambda$  に依存する.

$$\lambda = \sigma_\nu \sqrt{2 \log n} \approx 0.16$$

例 3.9  $m = 1, n = 2, \mathbf{A} = \begin{bmatrix} 1 & 0.5 \end{bmatrix}, b = 2.3$  とする.

- LASSO 回帰の目的関数

$$F_{\lambda}(\mathbf{x}) = \frac{1}{2} (2.3 - (x_1 + 0.5x_2))^2 + \lambda(|x_1| + |x_2|)$$




図 3.13 例3.9 ( $m = 1, n = 2$ ) の図解. 横軸を  $x_1$ , 縦軸を  $x_2$  として図示している. 等高線と  $\star$  は, 上段: LASSO 回帰, 中段: LASSO, 下段:  $\text{BP}_{\delta}$  の目的関数と解を表す. 中段の正方形および下段の平行線は, それぞれ LASSO と  $\text{BP}_{\delta}$  の制約条件が表す領域の境界である.

# スパース解をもつ凸緩和問題


□ BP: Basis Pursuit

□  $BP_\delta$ : Compressed Sensing

□ LASSO

□ LASSO regression / unconstrained BP denoising (BPDN) /  $\ell_1$ -regularized least squares ( $\ell_1$ -LS)


$$\underset{\mathbf{x}}{\text{Minimize}} \frac{1}{2} \|\mathbf{b} - \mathbf{Ax}\|_2^2 + \lambda \|\mathbf{x}\|_1$$



$\leq \delta$

operator

$\leq \tau$



- 勾配を使うと、止まらない.
- 解は微分不可能な位置にある.


# Soft thresholding/shrinkage

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2^2 + \lambda \|\mathbf{x}\|_1 = \text{soft}(\mathbf{b}, \lambda) \quad \text{if } \mathbf{A} = \mathbf{I} \text{ (identity).}$$

$$x_j^* = \arg \min_{x_j} \left( \frac{1}{2} (b_j - x_j)^2 + \lambda |x_j| \right) = \begin{cases} b_j - \lambda & (0 < \lambda < b_j) \\ 0 & (-\lambda \leq b_j \leq \lambda) \\ b_j + \lambda & (b_j < -\lambda < 0) \end{cases}$$

shrink each  $b_j$  by  $\lambda$

$$f_{b,\lambda}(x) = \frac{1}{2} (b - x)^2 + \lambda |x|$$



$$\arg \min_x f_{b,\lambda}(x) = \text{soft}(b, \lambda) = \text{sign}(b) \max(|b| - \lambda, 0)$$

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

$$\mathbf{x}^{(k+1)} := \text{soft} \left( \mathbf{x}^{(k)} + \frac{1}{L} \mathbf{A}^\top (\mathbf{b} - \mathbf{A}\mathbf{x}^{(k)}), \frac{\lambda}{L} \right)$$

- The constant  $L$  must be larger than the maximum eigenvalue of  $\mathbf{A}^\top \mathbf{A}$ .
- $\|\mathbf{x}^{(k)} - \mathbf{x}^*\| = \mathcal{O}(1/k)$
- IST can be derived from locally approximating the objective function with  $\mathbf{A}^\top \mathbf{A} \approx L\mathbf{I}$ .
- a.k.a. the proximal gradient method.

Ex.  $\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 2 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 2 \\ -2 \\ -1 \\ -1 \end{bmatrix}$   
 $\lambda = 0.1, L = 5, \mathbf{x}^{(0)} = \mathbf{A}^\top \mathbf{b}$

k	x
0	[2.00 -3.00 -4.00 -1.00 -1.00]'
10	[2.32 -0.97 -0.72 0.19 -0.50]'
20	[2.41 -0.78 -0.56 0.23 -0.39]'
30	[2.47 -0.67 -0.60 0.19 -0.33]'
40	[2.52 -0.57 -0.65 0.15 -0.28]'
50	[2.57 -0.47 -0.70 0.10 -0.23]'
60	[2.62 -0.37 -0.75 0.05 -0.18]'
70	[2.67 -0.27 -0.80 0.00 -0.13]'
80	[2.73 -0.19 -0.85 0.00 -0.07]'
90	[2.77 -0.13 -0.89 0.00 -0.03]'
100	[2.81 -0.07 -0.93 0.00 -0.00]'
...	[3.00 0.00 -1.00 0.00 0.00]'

# FISTA

Fast iterative soft thresholding algorithm [Beck&Teboulle, 09] [Nesterov, 83]

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

$$\mathbf{w}^{(1)} := \mathbf{x}^{(0)}, \quad t_1 := 1$$

$$\mathbf{x}^{(k)} := \text{soft} \left( \mathbf{w}^{(k)} + \frac{1}{L} \mathbf{A}^\top (\mathbf{b} - \mathbf{A}\mathbf{w}^{(k)}), \frac{\lambda}{L} \right)$$

$$t_{k+1} := \frac{1}{2} \left( 1 + \sqrt{1 + 4t_k^2} \right)$$

$$\mathbf{w}^{(k+1)} := \mathbf{x}^{(k)} + \frac{t_k - 1}{t_{k+1}} (\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)})$$

- $\|\mathbf{x}^{(k)} - \mathbf{x}^*\| = \mathcal{O}(1/k^2)$
- IST with the Nesterov acceleration


$$\text{Ex. } \mathbf{A} = \begin{bmatrix} 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 2 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 2 \\ -2 \\ -1 \\ -1 \end{bmatrix}$$

$\lambda = 0.1, \quad L = 10, \quad \mathbf{x}^{(0)} = \mathbf{A}^\top \mathbf{b}$

k	x
0	[2.00 -3.00 -4.00 -1.00 -1.00]'
10	[2.32 -0.87 -0.48 0.26 -0.49]'
20	[2.49 -0.68 -0.61 0.22 -0.31]'
30	[2.65 -0.31 -0.78 0.02 -0.15]'
40	[2.90 0.00 -0.98 -0.00 -0.00]'
50	[2.86 -0.00 -0.97 -0.00 -0.00]'
60	[2.85 -0.02 -0.95 -0.00 -0.00]'
70	[2.87 -0.00 -0.97 -0.00 -0.00]'
80	[2.87 -0.00 -0.97 -0.00 -0.00]'
90	[2.87 -0.00 -0.97 -0.00 -0.00]'
100	[2.87 -0.00 -0.97 -0.00 -0.00]'
...	[3.00 0.00 -1.00 0.00 0.00]'



# 近接点法 = 陰的(劣)勾配降下法



# スパース解をもつ凸緩和問題


□ BP: Basis Pursuit

□  $BP_\delta$ : Compressed Sensing

□ LASSO

□ LASSO regression / unconstrained BP denoising (BPDN) /  $\ell_1$ -regularized least squares ( $\ell_1$ -LS)


$$\underset{\mathbf{x}}{\text{Minimize}} \frac{1}{2} \|\mathbf{b} - \mathbf{Ax}\|_2^2 + \lambda \|\mathbf{x}\|_1$$



$\leq \delta$

operator

$\leq \tau$



- 勾配を使うと、止まらない.
- 解は微分不可能な位置にある.

# 近接写像の反復法

Proximal methods

□ 凸最小化問題 Minimize  $f_1(\mathbf{x}) + f_2(\mathbf{x}) + \cdots + f_n(\mathbf{x})$   
 $\mathbf{x} \in \mathbb{R}^{d_x}$

$f_1, \dots, f_n$  は凸関数で, そのいくつかは微分不可能

□ 近接作用素

$$\text{prox}_f(\mathbf{q}) = \arg \min_{\mathbf{x}} f(\mathbf{x}) + \frac{1}{2} \|\mathbf{x} - \mathbf{q}\|_2^2$$

近似解の更新に使う

- $\mathbf{p} = \text{prox}_f(\mathbf{q})$  とすると  $f(\mathbf{p}) \leq f(\mathbf{q})$  .
- $\mathbf{x}^{(k+1)} = \text{prox}_f(\mathbf{x}^{(k)}) \Leftrightarrow f(\mathbf{x}^{(k+1)}) \leq f(\mathbf{x}^{(k)}) \quad \because -(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}) \in \partial f(\mathbf{x}^{(k+1)})$  劣勾配降下
- 最小解  $\mathbf{x}^*$  は不動点 :  $\mathbf{x}^* = \text{prox}_f(\mathbf{x}^*) = \arg \min_{\mathbf{x}} f(\mathbf{x})$ .

□ 算法

- 反復ソフト閾値処理 (ISTA) / alternating projections / averaged projections / ADMM, etc.

## 近接作用素の例

$$\text{prox}_f(\mathbf{q}) = \arg \min_{\mathbf{x}} f(\mathbf{x}) + \frac{1}{2} \|\mathbf{x} - \mathbf{q}\|_2^2$$

□  $\ell_p$  ノルムの  $p$  乗 :  $f(\mathbf{x}) = \lambda \|\mathbf{x}\|_p^p$

•  $p = 2$  :  $\text{prox}_{\lambda \|\cdot\|_2^2}(\mathbf{q}) = \mathbf{q} / (2\lambda + 1)$

$\mathbf{q}$  を縮小する処理

•  $p = 1$  :  $\text{prox}_{\lambda \|\cdot\|}(\mathbf{q}) = \text{soft}(\mathbf{q}, \lambda)$

$\mathbf{q}$  の各成分を  $\lambda$  だけ切り詰める処理

□ 核ノルム  $\|\mathbf{A}\|_* = (\text{行列}\mathbf{A}\text{の特異値 } \boldsymbol{\kappa} = [\kappa_1, \dots, \kappa_r]^\top \text{の和}) = \|\boldsymbol{\kappa}\|_1$  ただし  $\mathbf{A} = \mathbf{U} \text{diag}(\boldsymbol{\kappa}) \mathbf{V}^\top$   
 $\mathbf{A}$  の低ランク性 (行または列の線形従属性) を表す凸関数

•  $f(\mathbf{x}) = \lambda \|\mathbf{A}\|_*$   $\text{prox}_{\lambda \|\cdot\|_*}(\mathbf{A}) = \mathbf{U} \text{diag}(\text{soft}(\boldsymbol{\kappa}, \lambda)) \mathbf{V}^\top := \text{svt}(\mathbf{A}, \lambda)$  (singular value thresholding)

□ 指示関数  $\iota_{\mathcal{C}}(\mathbf{x}) = \begin{cases} 0 & \text{if } \mathbf{x} \in \mathcal{C} \\ \infty & \text{otherwise} \end{cases}$  制約条件を満たすか否かを表す凸関数

•  $\mathcal{C}_{\mathbf{c}, \varepsilon} = \{\mathbf{x} \mid \|\mathbf{x} - \mathbf{c}\|_2 \leq \varepsilon\}$  :  $\text{prox}_{\iota_{\mathcal{C}_{\mathbf{c}, \varepsilon}}}(\mathbf{q}) = \mathbf{c} + \varepsilon \frac{\mathbf{q} - \mathbf{c}}{\|\mathbf{q} - \mathbf{c}\|_2}$

•  $\mathcal{C}_{\mathbf{A}, \mathbf{b}} = \{\mathbf{x} \mid \mathbf{A}\mathbf{x} = \mathbf{b}\}$  :  $\text{prox}_{\iota_{\mathcal{C}_{\mathbf{A}, \mathbf{b}}}}(\mathbf{q}) = (\mathbf{I} - \mathbf{A}^\top (\mathbf{A}\mathbf{A}^\top)^{-1} \mathbf{A}) \mathbf{q} + \mathbf{A}^\top (\mathbf{A}\mathbf{A}^\top)^{-1} \mathbf{b}$





図 4.3 閉凸集合  $C$  の標示関数  $\iota_C$  と  $C$  への近接写像.  $C$  の外部の点  $q \notin C$  の近接点  $\hat{x}$  は,  $q$  から最寄りの  $C$  の境界に位置する.

$$\begin{aligned} \text{prox}_{\iota_C}(q) &= \arg \min_x \iota_C(x) + \frac{1}{2} \|x - q\|_2^2 \\ &= \arg \min_{x \in C} \|x - q\|_2 \end{aligned}$$



$$\begin{aligned} \text{prox}_{\iota_C}(\mathbf{q}) &= \arg \min_{\mathbf{x}} \iota_C(\mathbf{x}) + \frac{1}{2} \|\mathbf{x} - \mathbf{q}\|_2^2 \\ &= \arg \min_{\mathbf{x} \in \mathcal{C}} \|\mathbf{x} - \mathbf{q}\|_2 \end{aligned}$$

図 4.7 閉  $\ell_2$  超球体  $\mathcal{B}_r^2(\mathbf{c})$  への近接写像. 閉  $\ell_2$  超球体外部の点  $\mathbf{q} \notin \mathcal{B}_r^2(\mathbf{c})$  の近接点  $\hat{\mathbf{x}}$  は, 中心  $\mathbf{c}$  から  $\mathbf{q} - \mathbf{c}$  の方向に距離  $r$  だけ移動した超球面  $\partial \mathcal{B}_r^2(\mathbf{c})$  の上に位置する.




図 4.8 閉  $\ell_1$  超球体  $\mathcal{B}_r^1(\mathbf{c})$  への近接写像.  $\mathcal{B}_r^1(\mathbf{c})$  外部の点  $\mathbf{q}_a$  と  $\mathbf{q}_b$  の近接点はそれぞれ  $\hat{\mathbf{x}}_a = \mathbf{c} + \text{soft}(\mathbf{q}_a - \mathbf{c}, \theta_a)$ ,  $\hat{\mathbf{x}}_b = \mathbf{c} + \text{soft}(\mathbf{q}_b - \mathbf{c}, \theta_b)$  である.

$$\hat{\mathbf{x}} = \text{prox}_{\ell_{\mathcal{B}_r^1(\mathbf{c})}}(\mathbf{q}) = \mathbf{c} + \text{soft}(\mathbf{q} - \mathbf{c}, \theta)$$

$$\theta \leftarrow \text{FindThresh}(\mathbf{q} - \mathbf{c}, r)$$

---

アルゴリズム 11 正軸体へ近接写像するための閾値（並べ替え法）<sup>126</sup>):  $\theta \leftarrow$

$\text{FINDTHRESH}(\mathbf{v}, r)$

入力:  $\mathbf{v} = [v_1, \dots, v_n]^\top \in \mathbb{R}^n$ , 正軸体の半径  $r \geq 0$ ;

出力:  $\theta$ : 閾値;

1  $\mathbf{v}$  の成分の絶対値を降順に並べたものを  $u_1, \dots, u_n$  とする;

2  $K \leftarrow \max_{k \in \{1, \dots, n\}} \{k \mid (\sum_{j=1}^k u_j - r)/k < u_k\}$ : 不等式を満たす最大の  $k$  を  $K$  とする;

3  $\theta = (\sum_{j=1}^K u_j - r)/K$ ;

---



---

アルゴリズム 12 正軸体へ近接写像するための閾値（アクティブセット法）<sup>127</sup>):

$\theta \leftarrow \text{FINDTHRESH}(\mathbf{v}, r)$

入力:  $\mathbf{v} = [v_1, \dots, v_n]^\top \in \mathbb{R}^n$ , 正軸体の半径  $r \geq 0$ ;

出力:  $\theta$ : 閾値;

1 台の初期値を  $\mathcal{T} \leftarrow \{1, \dots, n\}$  とする;

2 初期値  $\theta \leftarrow (\|\mathbf{v}\|_1 - r)/n$  を計算する;

3  $k \leftarrow 0$ ;

4 **while**  $|\mathcal{T}| \neq k$  **do**

5      $k \leftarrow |\mathcal{T}|$ ;

6      $\mathcal{T} \leftarrow \{j \mid |v_j| > \theta, j \in \mathcal{T}\}$ : 閾値  $\theta$  を超える  $\mathbf{v}$  の成分の番号を集合  $\mathcal{T}$  に残す;

7      $\mathbf{v}$  の台  $\mathcal{T}$  の成分のみから  $\theta \leftarrow (\|\mathbf{v}_{\mathcal{T}}\|_1 - r)/|\mathcal{T}|$  を計算する;

8 **end while**

---

# Proximal gradient and IST

Bruck, Lions, Mercier (1970s)

Minimize  $f(\mathbf{x}) + g(\mathbf{x})$  for smooth  $f$

$$\mathbf{x}^{(k+1)} = \text{prox}_{\gamma g}(\mathbf{x}^{(k)} - \gamma \nabla f(\mathbf{x}^{(k)}))$$

$$= \arg \min_{\mathbf{x}} \gamma \left( g(\mathbf{x}) + \frac{1}{2\gamma} \|\mathbf{x} - (\mathbf{x}^{(k)} - \gamma \nabla f(\mathbf{x}^{(k)}))\|_2^2 \right)$$

$$= \arg \min_{\mathbf{x}} \left( g(\mathbf{x}) + \nabla f(\mathbf{x}^{(k)})^\top (\mathbf{x} - \mathbf{x}^{(k)}) + \frac{1}{2\gamma} \|\mathbf{x} - \mathbf{x}^{(k)}\|_2^2 + \frac{1}{2\gamma} \|\nabla f(\mathbf{x}^{(k)})\|_2^2 + f(\mathbf{x}^{(k)}) \right)$$

$$= \arg \min_{\mathbf{x}} \left( g(\mathbf{x}) + f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^\top (\mathbf{x} - \mathbf{x}^{(k)}) + \frac{1}{2\gamma} \|\mathbf{x} - \mathbf{x}^{(k)}\|_2^2 \right)$$

- $\mathbf{x}^{(k+1)}$  minimizes  $g(\mathbf{x})$  plus the 2<sup>nd</sup> order Taylor approximation of  $f(\mathbf{x})$  around  $\mathbf{x}^{(k)}$ .

- If  $g(\mathbf{x}) = \lambda \|\mathbf{x}\|_1$ , we have IST:  $\mathbf{x}^{(k+1)} = \text{soft}(\mathbf{x}^{(k)} - \gamma \nabla f(\mathbf{x}^{(k)}), \gamma \lambda)$ .

- Special case: linear model fitting,  $\ell_2$  loss  $f(\mathbf{x}) = \frac{1}{2} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2^2$  and  $\gamma = \frac{1}{L}$ ;

$$\mathbf{x}^{(k+1)} = \text{soft}\left(\mathbf{x}^{(k)} + \frac{1}{L} \mathbf{A}^\top (\mathbf{b} - \mathbf{A}\mathbf{x}^{(k)}), \frac{\lambda}{L}\right)$$



# ADMM

Alternating direction method of multipliers [Gabay&Mercier, 76]

Minimize  $f(\mathbf{x}) + g(\mathbf{z})$  subject to  $\mathbf{z} = \mathbf{G}\mathbf{x}$   
( $\mathbf{x}, \mathbf{z}$ )

$$\begin{aligned}\mathbf{x}^{(k+1)} &:= \arg \min_{\mathbf{x}} f(\mathbf{x}) + \frac{\rho}{2} \|\mathbf{G}\mathbf{x} - (\mathbf{z}^{(k)} - \mathbf{u}^{(k)})\|_2^2 \\ \mathbf{z}^{(k+1)} &:= \arg \min_{\mathbf{z}} g(\mathbf{z}) + \frac{\rho}{2} \|\mathbf{z} - (\mathbf{G}\mathbf{x}^{(k+1)} + \mathbf{u}^{(k)})\|_2^2 \\ \mathbf{u}^{(k+1)} &:= \mathbf{u}^{(k)} + \mathbf{G}\mathbf{x}^{(k+1)} - \mathbf{z}^{(k+1)}\end{aligned}$$

# SALSA

Split augmented Lagrangian shrinkage algorithm [Afonso+, 10]

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

$$\begin{aligned} \mathbf{v} &:= \text{soft}\left(\mathbf{x}^{(k)} + \mathbf{y}^{(k)}, \frac{\lambda}{\rho}\right) - \mathbf{y}^{(k)} \\ \mathbf{x}^{(k+1)} &:= (\mathbf{A}^\top \mathbf{A} + \rho \mathbf{I})^{-1} (\mathbf{A}^\top \mathbf{b} + \rho \mathbf{v}) \\ \mathbf{y}^{(k+1)} &:= \mathbf{x}^{(k+1)} - \mathbf{v} \end{aligned}$$

- $\|\mathbf{x}^{(k)} - \mathbf{x}^*\| = \mathcal{O}(1/k)$
- converges  $\forall \rho > 0$
- derived from ADMM

$$\text{Ex. } \mathbf{A} = \begin{bmatrix} 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 2 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 & 1 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 2 \\ -2 \\ -1 \\ -1 \end{bmatrix}$$

$\lambda = 0.1, \rho = 5, \mathbf{x}^{(0)} = \mathbf{A}^\top \mathbf{b}$

k	x
0	[2.00 -3.00 -4.00 -1.00 -1.00]'
10	[2.52 -0.57 -0.65 0.15 -0.28]'
20	[2.77 -0.12 -0.89 -0.01 -0.03]'
30	[2.86 -0.00 -0.96 -0.00 0.00]'
40	[2.87 -0.00 -0.97 -0.00 0.00]'
50	[2.87 -0.00 -0.97 -0.00 0.00]'
60	[2.87 -0.00 -0.97 -0.00 0.00]'
70	[2.87 -0.00 -0.97 -0.00 0.00]'
80	[2.87 -0.00 -0.97 -0.00 0.00]'
90	[2.87 -0.00 -0.97 -0.00 0.00]'
100	[2.87 0.00 -0.97 0.00 0.00]'
...	[3.00 0.00 -1.00 0.00 0.00]'



